



分布式系统 Distributed Systems

陈鹏飞 数据科学与计算机学院

chchenpf7@mail.sysu.edu.cr

办公室: 超算5楼529d

主页: http://sdcs.sysu.edu.cn/node/3747





大纲

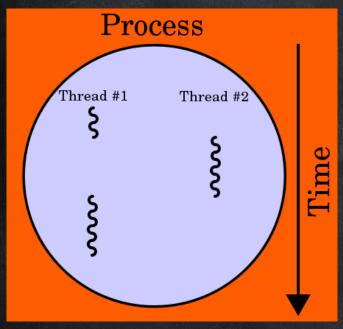
- 1 分布式系统中的线程
- 虚拟化
- 3 客户一服务器典型结构
- 4 计算迁移



分布式系统中的线程



进程



- ▶ 何为进程?
- > 何为线程?
- > 操作系统如何管理进程?

初始化、分配资源、调度、 销毁



▶ 基本思想:

在物理处理器上用软件创建虚拟处理器:

- □ 处理器: 提供和运行一系列指令集合的硬件平台;
- □ 线程: 一个最小的可执行一系列指令的软件处理器。 保存 线程的上下文意味着终止线程当前的执行, 在其他时刻装载 保存的线程上下文后, 线程可以继续执行;
- □ 进程:包含多个线程的软件处理器,线程需要在进程的上下 文中执行。

上下文切换

> 上下文

系统运行过程中的一系列状态,状态的含义因系统的不同而不同

- 处理器上下文
 - 处理器用于运行一系列指令的保存在寄存器中的最小数据集合 (如:栈指针、地址寄存器、程序计数器);
- □ 线程上下文

用于执行一系列指令的保存在寄存器和内存中的<mark>最小</mark>的数据集 合(如:处理器上下文、状态等);

□ 进程上下文

用于执行线程的保存在寄存器和内存中的最小的数据集合 (线程上下文、MMU寄存器值、TLB)



上下文切换

> 观察发现

- □ 线程共享相同的地址空间。 线程上下文的切换可以独立于操作系统;
- □ 一般来讲进程之间的切换要更复杂、代价更高,因为需要陷入到**OS**内核才能完成;
- 创建和销毁线程的代价要远远小于对进程的创建和销毁;



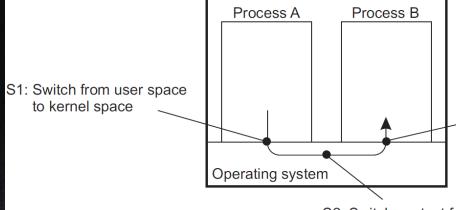
为什么要利用线程

主要的原因:

- 避免不必要的阻塞: 单线程的进程在进行I/O操作的时候会被阻塞; 在多线程的进程中,操作系统可以将CPU切换到进程的另外一个线程;
- 更好地发挥并行性: 一个具有多线程的进程可以在多核或者多处理器的CPU上并行执行;
- 避免进程上下文切换:架构大型应用的时候不是利用 多个进程而是多个线程;

避免进程切换

▶ 避免昂贵的上下文切换



S3: Switch from kernel space to user space

S2: Switch context from process A to process B

- □ 多个线程利用相同的地址空间: 更容易出错;
- □ 在线程使用内存时,没有来自OS/HW的保护;

□ 线程的上下文切换比进程的上下文切换要快得多;

平衡

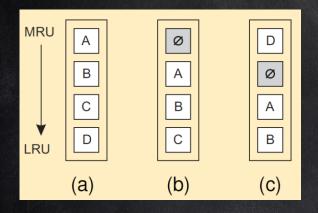


上下文切换的代价

考虑简单的时钟中断处理器:

- 直接代价: 用于实际切换和执行中断处理代码的时间;
- 间接代价: 其他代价, 比较常见的是cache刷新的时间;

上下文切换导致的间接代价:



- (a) 在上下文切换之前;
- (b) 在上下文切换之后;
- (c) 在访问区块D之后;

代价高达 80%



线程和操作系统

> 内核解决方案

基本的想法是在内核中实现软件包,这也就意味着所有的操作 变成系统调用;

- 用于阻塞线程的操作就不在是问题了,内核会在同一个进程中调度另外一个可用的线程;
- 处理外部事件也变得简单了:内核(捕捉所有的事件)直 接调度与线程相关的事件;
- 存在的问题是效率,因为每个线程操作都需要陷入到内核;

▶ 结论

尽可能融合用户级别和内核级别的线程,发挥各自的优势。但是, <u>事实上这种做法带来的性能提升也难以弥补</u>其复杂性带来的困难。







线程的实现

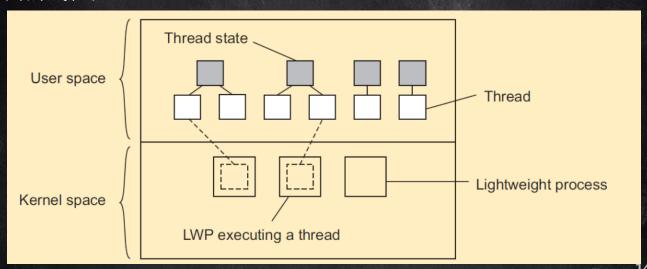
- > 线程的实现方式
 - 往往以线程包的形式存在;
 - 完全在用户空间下创建线程库;
 - 由内核来掌管线程并进行调度;
- ▶ 用户级线程
 - 好处:上下文切换代价小;
 - 缺陷:线程阻塞 -> 进程阻塞;



轻量级进程(LWP)

▶ 基本思想

引入一种两层线程方法: 轻量级的进程 (LWP) 能够执行用户空间的线程;



在客户端使用多线程

- > 多线程在分布式系统中的重要意义
- > 多线程的Web客户端

隐藏了网络的延迟;

- Web浏览器扫描到达的HTML页面,发现需要获取更多页面;
- 每一个页面由一个特定的线程获取,每个线程执行HTTP请求;
- 随着文件的到达,浏览器将这些文件展示出来;
- ▶ 服务器之间多个请求-响应调用
 - 客户端同时产生多个调用,每一个线程负责一个调用;
 - 之后,客户端等待结果返回
 - 注意: 如果调用的不同的服务器,将会得到线性加速;





多线程客户端是否有用?

Thread-level parallelism: TLP

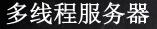
Let c_i denote the fraction of time that exactly i threads are being executed simultaneously.

$$TLP = \frac{\sum_{i=1}^{N} i \cdot c_i}{1 - c_0}$$

with N the maximum number of threads that (can) execute at the same time.

Practical measurements

A typical Web browser has a TLP value between $(.5 \text{ and } 2.5) \Rightarrow \text{threads are}$ primarily used for logically organizing browsers.



> 提高性能

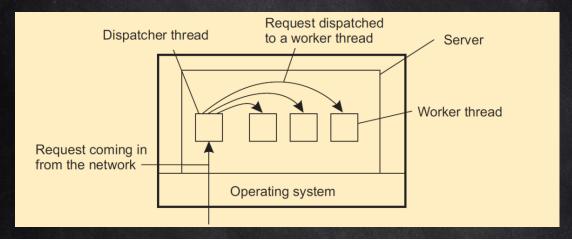
- □ 启动一个线程远比启动一个进程代价要小很多;
- □ 单线程服务很难再多处理器系统中实现 scale-up (纵向扩展);
- □ 与多线程客户端相呼应:通过并行响应请求隐藏网络延迟;

> 更好的结构

- □ 大部分服务器都具有较高的I/O需求,使用简单容易理解的阻塞调用可以简化整体结构;
- 多线程的程序的代码数量较少,比较容易理解,因为控制流被简化了;

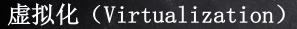


多线程服务器举例:文件服务器



模型	特征	
多线程	并行,使用会导致阻塞的系统调用	
单线程进程	非并行,使用会导致阻塞的系统调用	
有限状态机	并行,使用非阻塞系统调用	

图 3.4 构建服务器的 3 种方式



> 观察发现

虚拟化(软硬件的多路复用)非常重要:

- □ 硬件比软件变化的快;
- □ 需要灵活的可移植性和代码迁移;
- □ 失效和攻击隔离





虚拟化 (Virtualization)

▶ 主要原理: 模拟接口

Program

Interface A

Hardware/software system A

Program

Interface A

Implementation of mimicking A on B

Interface B

Hardware/software system B

模拟接口

- > 三个层次上的四种类型的接口
 - 指令集架构: 一系列的机器指令, 主要分为两类:
 - a. 特权指令:允许操作系统执行的执行;
 - b. 通用指令:可以被任何程序执行的指令;
 - 系统调用

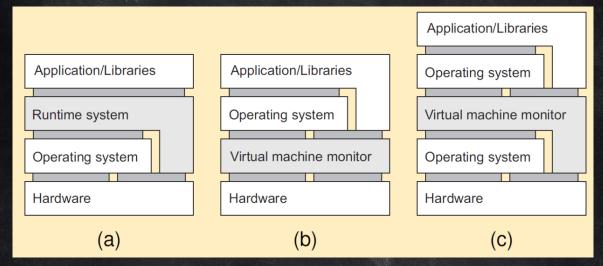
由操作系统提供的函数;

□ 库函数调用,也成为应用程序接口(API)



虚拟化的不同方式

(a) 进程虚拟机 (Process VM)、(b) 原生虚拟机监控器 (Native VM M)、(b) 主机虚拟机监控器 (Hosted VMM)

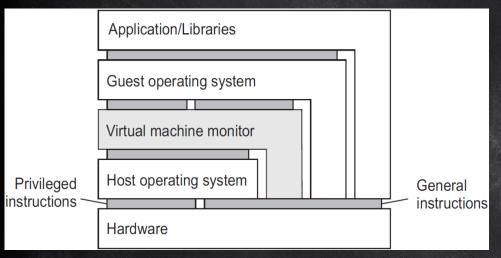


区别: (a) 分离的指令集合,实际是运行在操作系统之上的解释器(JVM)或者模拟器(Qemu); (b) 底层的指令,同时具有跑在硬件上的最小的操作系统; (c) 底层指令,但是需要一个完整的OS;





进一步了解虚拟机:性能



特权指令: 当且仅当在 用户模式下执行时, 引 起操作系统陷入;

非特权指令: 其他所有 指令

特殊指令:

控制敏感性指令: 可能影响到机器配置的指令(如: 寄存器重定位

或者中断表)

行为敏感性指令: 指令效果由上下文确定;

虚拟化的条件

> 采用虚拟化的必要条件

对于任何通用计算机,如果敏感指令集是特权指令的子集,则可 以构建虚拟机监控器;

问题:条件并不总是被满足

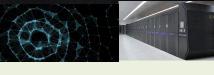
存在这样的敏感指令集,这些指令集在用户空间执行,但是不会引起操作系统的陷入;

▶ 解决方案:

模拟所有指令;

包装非特权敏感指令,将其交给VMM控制执行;

半参数化(Paravirtualization):修改客户OS,要么阻止非特权的敏感指令,或者将其变为非敏感指令(也就是改变上下文);



客户-服务器之间的交互

客户机器主要是让个人用户和远程服务器交互。主要包含两种模式: 1、对于每种远程服务,客户机都有一个独立的网络模块联系这些服务; 2、通过一个方便统一的用户接口来对远程服务直接访问;

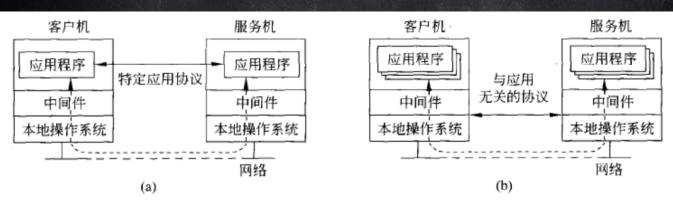


图 3.8

(a) 带自用协议的网络连接的应用程序; (b) 允许访问远程应用程序的通用解决方案



样例: X windows系统

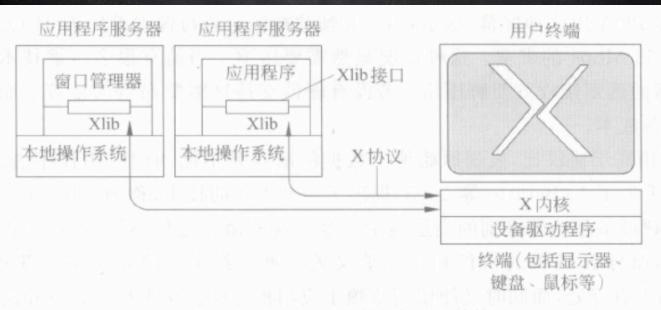


图 3.9 X Window 系统基本组织结构



提高X Windows系统性能

> 实际观察

- 应用程序的逻辑和用户接口之间没有清晰的界限;
- □ 应用程序与X内核之间的交互倾向于采用同步模式;

> 改进方法

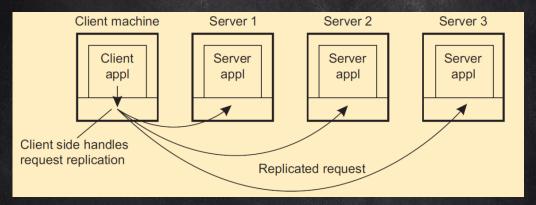
- 应用程序完全控制显示,可以到像素级别(VNC);
- 提供几种高层次的显示操作;



客户端软件

客户端软件包含用于获得分布式透明性的组件

- 访问透明性:客户端拥有用于RPC访问的存根;
- 位置/迁移的透明性: 让客户端记录服务器的实际位置;
- 副本透明性:客户端存根多个副本的调用



■ 故障透明性: 经常放在客户端(用于屏蔽服务器和通信问题)



> 基本模型:

服务器是实现特定服务的进程,这些服务是为一组客户提供的。本质上,每个服务器的组织方式都一样,等待来自客户的请求,随后负责处理该请求。



> 两种基本类型

- 迭代服务器(Iterative server): 服务器顺序处理到达的 请求;
- 并发服务器(Concurrent server): 利用分派器(dispatch er),选择到达的请求并将它传递给分离的线程或者进程处理;

> 观察发现

并发服务器是一种常见的类型:他们能够处理多个请求, 特别是针对某些阻塞性的操作;









服务器连接

		# EtherNet/IP messaging
		# EtherNet/IP messaging
m3da	44900/tcp	# M3DA (efficient machine-to-machine com
munication)	44000/1-	# MOD3 Prince
m3da-disc achine communica	44900/udp	# M3DA Discovery (efficient machine-to-m
		# NSi AutoStore Status Monitoring Protoc
ol data transfer		# MSI Autostore Status Monitoring Protoc
		# NSi AutoStore Status Monitoring Protoc
ol device monito		Not haddoode boadab homitoting ficoso
		# NSi AutoStore Status Monitoring Protoc
ol secure data 1	ransfer	
synctest	45045/tcp	# Remote application control
invision-ag	45054/tcp	# InVision AG
invision-ag	45054/udp	# InVision AG
eba	45678/tcp	# EBA PRISE
eba		# EBA PRISE
	45824/tcp	# Server for the DAI family of client-se
rver products		
		# Qpuncture Data Access Service
qdb2service		# Opuncture Data Access Service
ssr-servermgr		# SSRServerMgr
ssr-servermgr		# SSRServerMgr
sp-remotetablet	46998/tcp	# connection between computer and a sign
ature tablet		
	46999/tcp 46999/udp	# MediaBox Server # MediaBox Server
mbus		# Message Bus
		# Message Bus
winrm		# Windows Remote Management Service
		# Configuration of motors conneced to in
dustrial etherne		
dbbrowse		# Databeam Corporation
dbbrowse	47557/udp	# Databeam Corporation
directplaysrvr		# Direct Play Server
directplaysrvr		# Direct Play Server
ap	47806/tcp	# ALC Protocol
ap	47806/udp	# ALC Protocol
bacnet	47808/tcp	# Building Automation and Control Networ
ks		
bacnet	47808/udp	# Building Automation and Control Networ
ks		
nimcontroller		# Nimbus Controller
nimcontroller		# Nimbus Controller
		# Nimbus Spooler
nimspooler		# Nimbus Spooler
nimhub		# Nimbus Hub
nimhub		# Nimbus Hub
nimgtw		# Nimbus Gateway
nimgtw	48003/udp	# Nimbus Gateway

静态端口配置:	1.0000	10000000
时念》,	=/DFOC/	Services
	, 6.00,	301 11003

tcp	0	127.0.0.1:43984	127.0.0.1:2379	ESTABLISHED
tcp			127.0.0.1:57092	TIME_WAIT
tcp		127.0.0.1:2379	127.0.0.1:43908	ESTABLISHED
tcp		222.200.180.178:40316	222.200.180.178:9999	ESTABLISHED
tcp		222.200.180.178:39780	222.200.180.178:6443	ESTABLISHED
tcp		222.200.180.178:60560	222.200.180.178:9090	ESTABLISHED
tcp		222.200.180.178:9090	222.200.180.178:60564	ESTABLISHED
tcp			127.0.0.1:45296	TIME_WAIT
tcp		127.0.0.1:43992	127.0.0.1:2379	ESTABLISHED
tcp		127.0.0.1:43918	127.0.0.1:2379	ESTABLISHED
tcp		222.200.180.178:39876	222.200.180.178:6443	ESTABLISHED
tcp		222.200.180.178:39920	222.200.180.178:6443	ESTABLISHED
tcp		127.0.0.1:2379	127.0.0.1:43938	ESTABLISHED
tcp		222.200.180.178:39802	222.200.180.178:6443	ESTABLISHED
tcp		222.200.180.178:36878	222.200.180.178:3306 222.200.180.178:60556	ESTABLISHED ESTABLISHED
tcp		222.200.180.178:9090		
top		127.0.0.1:43946	127.0.0.1:2379	ESTABLISHED ESTABLISHED
tcp		127.0.0.1:2379	127.0.0.1:43898	TIME WAIT
top		127.0.0.1:2379	127.0.0.1:43880	ESTABLISHED
tcp		127.0.0.1:2379	127.0.0.1:43880	TIME WAIT
tcp		127.0.0.1:10251	127.0.0.1:80262	ESTABLISHED
		222.200.180.178:60556	222.200.180.178:9090	ESTABLISHED
tcp		222.200.180.178:80336	10.96.0.1:443	ESTABLISHED
tcp		127.0.0.1:2379	127.0.0.1:43888	ESTABLISHED
tcp		127.0.0.1:2379	127.0.0.1:43946	ESTABLISHED
tcp		222.200.180.178:60564	222.200.180.178:9090	ESTABLISHED
tcp		127.0.0.1:43990	127.0.0.1:2379	ESTABLISHED
top		127.0.0.1:10251	127.0.0.1:60306	TIME WAIT
tcp		127.0.0.1:43876	127.0.0.1:2379	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.184:38702	ESTABLISHED
tcp6		127.0.0.1:6443	127.0.0.1:43500	ESTABLISHED
tcp6		222.200.180.178:6443	10.96.0.9:35037	ESTABLISHED
tcp6		222.200.180.178:3306	222.200.180.178:36878	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:35376	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.183:55776	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:42364	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:39898	ESTABLISHED
tcp6		222.200.180.178:3306	222.200.180.178:36220	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:54102	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.179:34888	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.184:38690	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:39802	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:54086	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:39942	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:39780	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:39972	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:39168	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.178:39604	ESTABLISHED
tcp6		222.200.180.178:6443	222.200.180.183:43114	ESTABLISHED

动态连接查询: netstat -n



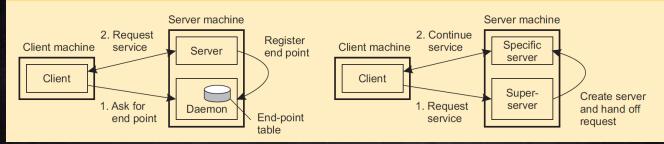


服务器连接

> 观察发现: 大多数服务都跟一个特定的端口绑定在一起

ftp-data	20	File Transfer [Default Data]
ftp	21	File Transfer [Control]
telnet	23	Telnet
smtp	25	Simple Mail Transfer
WWW	80	Web (HTTP)

▶ 动态分配一个端口









带外通信

▶ 问题

在服务器已经接收了服务器请求后,是否有可能中断服务器的运行?

- ▶ 解决方案1: 利用一个分开的端口用于紧急数据通信
 - 服务器拥有一个分离的线程或者进程用于紧急通信;
 - 紧急信息到达 => 相关联的请求暂时挂起;
 - □ 注意: 我们需要 OS 支持基于优先级的调度策略;
- ▶ 解决方案2: 利用传输层的机制
 - 样例: TCP 允许在同一个连接中传输紧急信息;
 - 利用OS的信号机制捕捉紧急信息;





服务器和状态

➤ 无状态服务器(Stateless servers)

在处理完请求后,从来不保存关于客户端的精确的信息;

- 不记录一个文件是否被打开(文件请求完成就关闭);
- 不保证清空客户端的cache;
- 不去追踪客户的信息;
- > 结果
 - 客户端和服务器完全独立;
 - 由于客户端或者服务器的宕机导致的状态不一致减少;
 - 由于服务器不能预测客户端的行为,可能导致性能下降;
- ▶ 问题

面向连接的通信是否适用于无状态的设计?

服务器和状态

➤ 有状态服务器(Stateful servers)

记录客户端的状态信息:

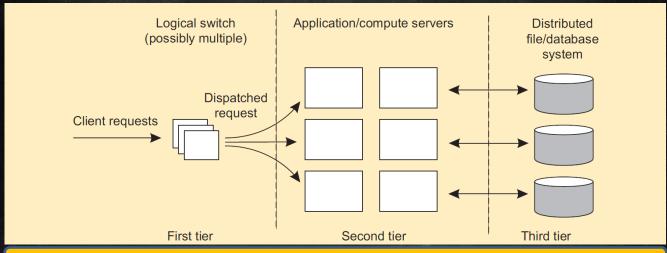
- 记录客户端打开的文件,这样可以提前实现预取;
- 知道客户端缓存了哪些数据,允许客户端在本地保存共享数据的备份:
- > 观察发现
 - 有状态的服务器的性能非常高;
 - 可靠性问题是一个主要的问题;





服务器集群

> 常见的组织结构



> 关键单元

■ 第一层主要用于请求分发 (掩盖分布式系统的分布式特性)



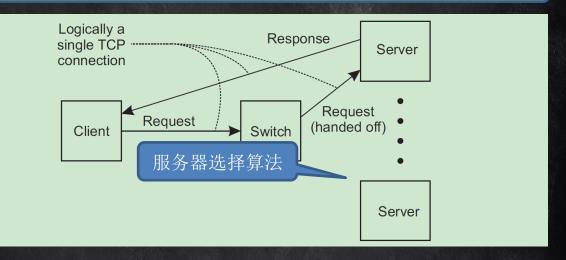




请求处理

- > 观察
 - □ 让第一层处理所有的出入集群的通信会导致性能瓶颈;

> 观察





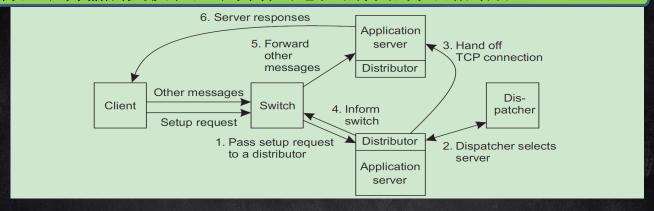


服务器集群

前端容易出现过载的情况:需要一种新的度量方法

- □ 基于传输层交换方法:前端简单地将TCP请求传递到服务器,只 是会考虑某些简单的性能指标如CPU利用率等;
- 基于内容可感知的分派方法: 前端会读取请求的内容, 然后选择 最合适的服务器;

将基于传输层交换和基于内容可感知的分派方法相结合



当服务器扩展到整个互联网

> 观察发现

将服务器集群扩展到互联网规模可能会引入管理问题。可以通过采用单个云计算商提供的数据中心避免这些问题。

▶ 请求分派: 如果局部性比较重要的话

常用的方法是利用DNS:

- 客户端通过DNS查询特定的服务-客户端的IP地址是请求的一部分;
- □ DNS服务器记录请求服务的副本服务器信息,并且返回大部分本 地服务的地址;

> 客户透明性

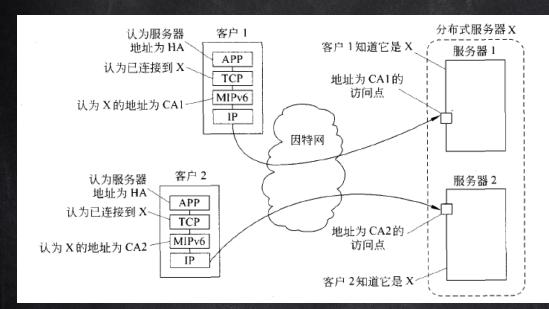
为了保障透明性,DNS resolver会代替客户端,问题是有可能距离远。



分布式服务器访问的稳定性

分布式服务器的基本思想是构造一个可靠的、高性能的、稳定的服务器即实现一个稳定的访问点。

▶ 具有稳定IPv6地址的分布式服务器





分布式服务器: 处理细节

- 客户端具有Mobile IPV6能够透明地跟任意其他节点建立 连接
- □ 客户端 C 通过IPv6 与宿主网络 HA 建立连接;
- HA 被一个宿主代理维护着,HA 可以将连接传递给注册的需要地 址 CA:
- C 可以应用路由优化方法,通过将网络包直接转发到地址 CA (不用传递给宿主agent);
- 协作分布式系统
- 原始的服务器维护一个宿主地址,但是会将连接信息传递给协作 节点:
- 原始节点和协作节点看起来是一个服务器;



管理服务器: PlanetLab

- > 本质
- □ 不同的组织贡献机器, 这些机器被共享用于进行各种实验;

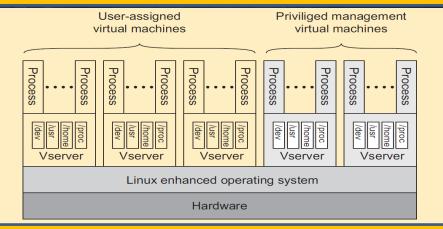
开放计算联盟

- ▶ 本质
- □ 我们需要保证不同的分布式应用相互不影响 => 虚拟化





▶ 总览



Vserver

■ 具有自己的软件库、服务器版本等的独立受保护环境。分布式应 用会分发到多个这样的机器上。

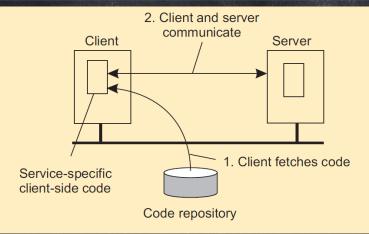


代码迁移

> 负载分布

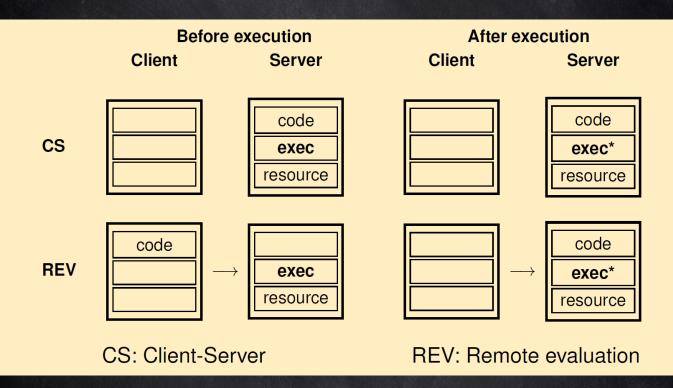
- □ 确保数据中心中的服务器的复杂运行更加充分(防止浪费能源)
- □ 让计算更加贴近数据端,最小化通信代价(例如移动计算)

> 灵活性: 当需要的时候将代码迁移到客户端



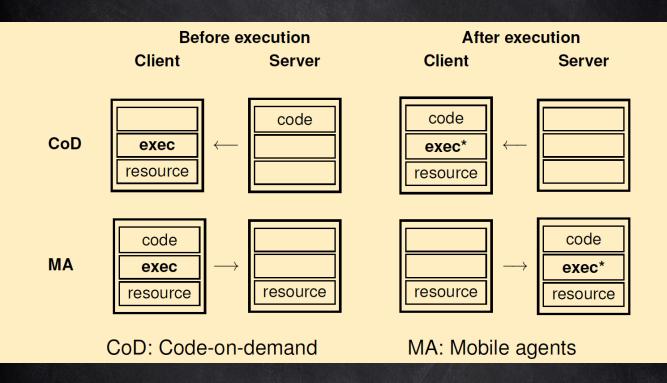
A B

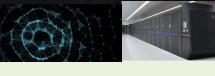
代码迁移的模型



25

代码迁移的模型





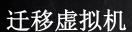
强/弱可移动性

- > 对象组件
- 代码片段:包含实际执行的代码;
- 数据片段:包含状态
- 执行状态:包含线程执行对象代码的上下文;
 - 弱移动性:仅仅移动代码和数据片段(重启执行)
- 相对简单,特别是如果代码是可移植的;
- 需要区分两种模式:代码推送(Push)和代码拉取(Pull)
- ▶ 强移动性:移动组件,包括执行状态
- 迁移(Migration):将整个对象从一个机器移动到另外一个机器;
- 克隆(Cloning): 开始克隆,将其设置为相同的执行状态;



异构系统中的迁移

- > 主要问题
- □ 目标机器可能不适合执行迁移后的代码;
- □ 进程/线程/处理器的上下文的定义比较依赖于硬件、操作系统和 运行时系统;
- > 仅有的解决方案: 在不同的平台上抽象机器的实现
- 解释型语言,拥有自己的VM;
- □ 虚拟机监控器;



- ▶ 迁移镜像:三个不同的方案
- 将内存内容推送到新的机器,在迁移过程中重新发送被修改过的 页面;
- □ 停止当前的虚拟机; 迁移内存, 然后重新启动虚拟机;
- □ 让新的虚拟机按需拉取内存页面: 在新的虚拟机上立即创建进程, 并且按需拷贝内存页面;





虚拟机迁移的性能

▶ 问题

一次完整的虚拟机迁移可能需要几十秒。在迁移期间,服务可能处于几秒钟的完全不可用的状态。

> 在虚拟机迁移过程中虚拟机响应时间的度量

